

ANÁLISE DE DADOS COM PYTHON

[T2]

Mini-Projeto Avaliativo - Módulo 2 - Semana 7

SUMÁRIO

1. CONTEXTUALIZAÇÃO	1
2. DESAFIO	1
3. RESULTADOS ESPERADOS (ENTREGA)	3
4. REQUISITOS DAS TAREFAS	4
4.1. GRAVAÇÃO DE VÍDEO	7
5. CRITÉRIOS DE AVALIAÇÃO	8
6. ENCARTE - AS BASES QUE VOCÊ RECEBEU	10
7. ENCARTE - O MODELO QUE VOCÊ DEVE CONSTRUIR	11
8. ENCARTE - NÚMEROS DE CONFERÊNCIA	14
9. ANEXOS- Base de Dados para Utilização no Mini-Projeto:	15

1. CONTEXTUALIZAÇÃO

A Pata Amiga é uma rede catarinense de pet shops. Começou com uma loja em Blumenau, em 2009, e hoje tem 32 lojas espalhadas pelo estado, de Itapoá a São Miguel do Oeste.

Em setembro de 2023 a rede ligou a operação de pedidos com entrega + app, site, telefone, WhatsApp e a própria loja física. Em sete meses foram 4.044 pedidos. A diretoria quer usar esses sete meses para decidir o próximo ciclo: onde está o gargalo da entrega, qual categoria sustenta o faturamento, se a política de desconto funciona igual em todo canal, e onde abrir a próxima loja.

O dado existe. O problema é que ele está em três sistemas que não se falam: a plataforma de e-commerce (os pedidos e os marcos da entrega), o cadastro de lojas do franchising, e a planilha de praças de atendimento que o time de expansão mantém à parte. Cada um escreve do seu jeito: a mesma loja aparece com acento, sem acento, em caixa alta e com erro de digitação; a mesma categoria tem várias grafias; data e dinheiro vêm como texto.

Reorganizar dados não parece grande coisa até você ver o que aparece do outro lado. Quando as três bases finalmente conversam, frases assim saltam da tela: que o gargalo não está na entrega, e sim entre a nota fiscal e o despacho; que uma praça concentra faturamento muito acima do seu número de domicílios com pet.

2. DESAFIO

Você foi contratado como analista de dados da Pata Amiga. A diretora foi direta: “Não quero um painel bonito. Quero cinco respostas, com número, e quero saber de onde veio cada número.”

As cinco perguntas de negócio

As cinco perguntas de negócio

- **P1 : Onde está o gargalo da entrega?** Qual o tempo médio, em dias, entre o pedido entrar no ERP e chegar na casa do cliente? E qual dos quatro intervalos do processo Integração → Separação, Separação → Nota, Nota → Despacho, Despacho → Entrega é o mais lento? O gargalo é o mesmo nos três portes de loja?
- **P2 : Qual categoria concentra o faturamento?** Do faturamento total da rede, quanto vem de cada categoria de produto? Agrupe pelo nome padronizado, nunca pela grafia crua, e mostre também o percentual do total. A categoria campeã é a mesma nos três portes de loja?
- **P3 : O desconto funciona igual em todo canal?** Compare o ticket médio COM e SEM desconto dentro de cada canal de venda (App, Site, Loja Física, Telefone, WhatsApp). Se o desconto derruba o ticket em um canal e não em outro, a política não deveria ser a mesma nos dois. Diga também quanto cada canal representa do faturamento.
- **P4 : Qual praça de atendimento concentra o faturamento?** Atenção: uma loja entrega em mais de uma praça. O rateio precisa ser feito pelo percentual do público, e a soma por praça tem de fechar com o faturamento da rede. Cruze o faturamento rateado com o número de domicílios com pet de cada praça.
- **P5 : Onde abrir a próxima loja, e o que os dados NÃO permitem afirmar?**
 - a) Ranqueie as lojas por itens vendidos por mil habitantes da cidade não em valor absoluto e cruze com o tempo médio de entrega.
 - b) A faixa de franquia no cadastro é a de hoje: o passado foi sobrescrito. Mostre o faturamento por faixa ATUAL e explique por que isso não responde “quanto veio de lojas que JÁ ERAM Ouro na data do pedido”.
 - c) Meça o que ficou de fora: pedidos sem loja identificada, entregas ainda não concluídas, itens e valores em branco.

O que chegou até você

A área de staging já está montada no banco dw_pata_amiga, com três tabelas carregadas exatamente como vieram dos sistemas de origem. Elas não podem ser alteradas: nada de UPDATE, nada de ALTER. Todo tratamento acontece nos INSERT das dimensões e da fato.

- Todas as colunas são VARCHAR. Data é texto. Valor em reais é texto. Quantidade é texto.

- Os nomes das colunas não estão em snake_case. Vieram do sistema de origem, com espaço, ponto e parêntese. Neste banco, esses nomes só funcionam entre crase: `Cod Loja`, `QTD.Itens`, `ValorLiquidoPedido(R\$)`.
- As datas do pedido e as datas do processo estão em formatos diferentes, e as duas convivem na mesma tabela. A plataforma de e-commerce é de um fornecedor norte-americano e nunca foi localizada: as datas de pedido vêm em MM/DD/AAAA com AM/PM. Os quatro marcos da entrega, não: vêm em AAAA-MM-DD.
- A mesma loja aparece escrita de dezenas de maneiras: com acento, sem acento, em caixa alta, com "/SC" no fim, com espaço sobrando e com erro de digitação.
- A mesma categoria de produto tem várias grafias: "Ração", "RACAO", "Rac.", "Alimento Seco" e uma pegadinha: "Ração Medicamentosa" não é ração, é medicamento.
- "Houve desconto?" e "canal do pedido" chegam com dezenas de grafias cada um, incluindo vazio. São poucos valores distintos, mas sujos.
- Marco de processo em branco não é erro: é processo em aberto. 1.953 pedidos ainda não foram entregues até o fim da janela.

3. RESULTADOS ESPERADOS (ENTREGA)

A entrega tem duas partes, submetidas em lugares diferentes.

1) O projeto um repositório público no GitHub, contendo:

- README.md o documento principal. Explica o case, o modelo que você construiu, as decisões que tomou e as cinco respostas com os números. É por ele que a correção começa.
- Os seus scripts SQL, na ordem em que devem ser rodados, com comentários. Quem clonar o repositório tem de conseguir reproduzir o seu banco do zero.
- O diagrama do modelo (estrela), em imagem, dentro do README. Veja abaixo o que ele precisa mostrar.

2) O vídeo de até 5 minutos, entregue pelo AVA.

2) O vídeo de até 5 minutos, entregue pelo AVA.

- Grave-o conforme a seção 4.1, coloque em uma pasta do Google Drive em modo leitor para qualquer pessoa com o link, e submeta esse link na tarefa do AVA, junto com o link do repositório. Uma dica: inserir o vídeo também no README do seu repositório.

- **Prazo de entrega: 14/09/2026, até as 22h.**

- **Peso na média do módulo: 25%.**

O trabalho é individual. Você pode conversar com os colegas sobre o problema é assim que se trabalha, mas o texto, o SQL e o vídeo devem ser seus.

Sobre o diagrama do modelo

Não há ferramenta obrigatória. Pode usar draw.io (diagrams.net), dbdiagram.io, Excalidraw, Lucidchart, PowerPoint ou desenhar à mão e fotografar. O que vale é estar legível e correto. Exporte em PNG ou JPG e coloque a imagem dentro do README.

O diagrama deve mostrar quatro informações:

- A fato_pedido no centro, com o grão escrito ao lado ("1 linha = 1 pedido").
- As dimensões em volta, ligadas à fato: dim_tempo, dim_loja e dim_categoria.
- A dim_tempo ligada DUAS vezes (data do pedido e data da entrega): é a mesma tabela em dois papéis, e o diagrama precisa deixar isso visível.
- A dim_praca ligada à dim_loja através da bridge_loja_praca, e não direto à fato é o único caminho indireto do modelo.

Não há necessidade de listar todas as colunas de cada tabela: o nome da tabela, a chave e dois ou três atributos bastam. Avalia-se a estrutura, não o capricho do desenho.

4. REQUISITOS DAS TAREFAS

De quanto SQL você precisa

Não é preciso SQL avançado. Esta é a lista fechada do que o projeto inteiro usa se você se pegar precisando de algo fora dela, provavelmente há um caminho mais simples:

- CREATE TABLE, INSERT INTO ... VALUES, INSERT INTO ... SELECT
- SELECT, SELECT DISTINCT, WHERE, GROUP BY, HAVING, ORDER BY
- JOIN e LEFT JOIN
- CASE WHEN ... THEN ... ELSE ... END
- agregação: SUM, COUNT, COUNT(DISTINCT ...), MAX, AVG, ROUND
- texto e conversão: UPPER, TRIM, REPLACE, SUBSTRING, CAST e STR_TO_DATE(<coluna>, '%m/%d/%Y %h:%i %p') para converter data
- distância entre duas datas, em dias: DATEDIFF(<data de fim>, <data de início>)

Você não precisa criar funções nem procedures, e não vai usar CTE, window function, trigger ou índice. Nas suas tabelas, basta declarar a PRIMARY KEY.

Subconsulta só nas perguntas de negócio. Na carga das dimensões e da fato não use nenhuma: se você precisou de uma para achar a linha da dimensão, é sinal de que a grafia crua não foi guardada onde deveria.

Não crie camada intermediária. As únicas tabelas do seu banco devem ser as três stg_ que já vieram prontas, as duas dimensões entregues, as dimensões que você criar e a sua fato. Sem view, sem tabela auxiliar, sem UPDATE.

Tarefa 1 : Diagnóstico da origem

Abra as três tabelas e escreva, no README, o que está errado em cada uma. Quantas grafias de loja existem? Quantas de categoria? Quantos pedidos vieram sem código de loja? Quantos sem nome de loja? Quantos marcos de processo estão em branco? Este

diagnóstico vale nota, e é ele que orienta todo o resto. Confira as contagens com o quadro da seção 8.

Tarefa 2 : Tratamento

As máscaras de data que você vai precisar:

Onde	Como vem	Como converter
DtHoraPedido, DtHoraIntegracaoERP	11/16/2023 02:30 PM	STR_TO_DATE(<coluna>, '%m/%d/%Y %h:%i %p')
Os 4 marcos da entrega	2023-11-16	DATE(<coluna>)
A chave da dim_tempo	vira 20231116	CAST(DATE_FORMAT(<a data>, '%Y%m%d') AS SIGNED)

ATENÇÃO: a data do pedido está no formato americano. Usar '%d/%m/%Y' NÃO dá erro: o MySQL devolve NULL e datas trocadas, em silêncio. É o erro mais caro desta base, porque nada na tela avisa.

A regra dos números:

Se o valor for	Faça
vazio ou '-'	grave NULL, nunca 0
'R\$ 1.850,00'	tire 'R\$' e o espaço, tire o ponto de milhar, troque a vírgula por ponto
'1850.00'	já está pronto, só converter
'1.200' (milhar, sem decimal)	tire o ponto antes de converter
texto para inteiro	CAST(<x> AS SIGNED)

O valor em reais é o caso exigente: “R\$ 1.850,00”, “1850.00”, “1.200”, “-” e vazio convivem na mesma coluna. A expressão abaixo já está pronta use-a para vl_liquido. A decisão que interessa continua sendo sua: reconhecer que “” e “-” viram NULL, e nunca 0. Uma amostra de como poderia ser corrigido.

```
CASE WHEN TRIM(REPLACE(<coluna>,'R$','')) IN ('','-') THEN NULL
      WHEN <coluna> LIKE '%,%'
      THEN CAST(REPLACE(REPLACE(REPLACE(REPLACE(<coluna>,'R$',''),' ',''),',','.'),',','.'))
      AS DECIMAL(15,2))
      ELSE CAST(REPLACE(REPLACE(<coluna>,'R$',''),' ','') AS DECIMAL(15,2)) END
```

O de-para das categorias. A ORDEM IMPORTA: “Ração Medicamentosa” contém “RA”, então se você testar RA antes de MED o item vai para a categoria errada e a P2 sai com o número trocado. Todo trecho testado é SEM acento, para o resultado não depender da instalação.

Grave os valores da tabela abaixo EXATAMENTE como estão escritos, sem acento (Racao, Alimentacao, Servico, Nao Informado). É assim que eles ficam no banco, e é assim que a conferência espera encontrá-los.

Ordem	Se contém	nome_categoria	grupo_categoria
1	MED	Medicamento	Saude e Higiene
2	PETISC	Petisco	Alimentacao
3	RA	Racao	Alimentacao
4	HIG	Higiene	Saude e Higiene
5	BRINQ	Brinquedo	Bem-estar
6	ACESS	Acessorio	Bem-estar
7	SERV	Servico	Bem-estar
	nenhum dos acima	Nao Informado	Nao Informado

O nome da loja. Parte 1, mecânica: REPLACE tira o sufixo “/SC” e o espaço duplo. Parte 2, decisão sua: erro de digitação, apelido e abreviação não saem com REPLACE precisam de um CASE escrito à mão. São só três, e são estas as grafias que sobram depois da parte 1:

Grafia que aparece na origem	Deve virar	Tipo
PATA AMIGA BLUMENAL CENTRO	PATA AMIGA BLUMENAU CENTRO	erro de digitação
PATA AMIGA FLORIPA NORTE	PATA AMIGA FLORIANOPOLIS NORTE	apelido
PATA AMIGA JGUA DO SUL	PATA AMIGA JARAGUA DO SUL	abreviação

Acento e maiúscula neste banco: A collation padrão do MySQL ignora acento e caixa: 'Timbo', 'TIMBO' e 'Timbó' são o MESMO texto para ele. Confira com SELECT 'Timbo' = 'TIMBO'; (devolve 1). Por isso o lookup da loja não precisa normalizar acento.

Tarefa 3 : Construir as dimensões

Duas dimensões já vêm prontas no 02-dimensoes-prontas.sql: dim_tempo e dim_loja. Você não constrói nenhuma das duas, mas precisa usá-las corretamente.

Você constrói duas dimensões e uma tabela ponte: dim_categoria, dim_praca e bridge_loja_praca. Os campos de cada uma estão na seção 7.

- A PK é uma surrogate key inteira (INT AUTO_INCREMENT PRIMARY KEY).

- A chave natural (a grafia, o código da praça) fica como atributo.
- Toda dimensão tem a linha -1 = "Nao Informado", inserida ANTES do INSERT ... SELECT, para nenhuma FK ficar nula.
- Na dim_categoria, guarde a GRAFIA CRUA em categoria_origem: é por ela que a fato encontra a linha, com um JOIN de uma linha só. Esse é o padrão central da semana.

Tarefa 4 : Construir a fato

fato_pedido uma linha por pedido. 4.044 linhas. É um único INSERT ... SELECT, sem subconsulta: só SELECT, JOIN, LEFT JOIN e CASE WHEN.

A regra que organiza o arquivo: a limpeza fica na dimensão, e a fato apenas procura a linha certa. Nenhuma FK fica nula quando o dado falta, ela aponta para a linha -1.

As cinco colunas de dias, calculadas UMA vez aqui na carga. Atenção: são QUATRO intervalos do processo mais o TOTAL a última linha da tabela não é um intervalo, é o processo inteiro, e é ela que responde a P1.

Coluna	Marco de início	Marco de fim
dias_integracao_separacao	DtHoraIntegracaoERP	Dt Separacao Estoque
dias_separacao_nota	Dt Separacao Estoque	DtNotaFiscal
dias_nota_despacho	DtNotaFiscal	Dt_Despacho_Transportad ora
dias_despacho_entrega	Dt_Despacho_Transportadora	DtEntregaCliente
dias_total_ate_entrega	DtHoraIntegracaoERP	DtEntregaCliente

Se o marco de FIM vier em branco, grave NULL nunca 0. AVG ignora NULL, mas soma o zero: um zero no lugar de "não aconteceu" faria o gargalo da P1 parecer mais rápido do que é.

Se você travar no arquivo 04

O 04 é o único ponto do projeto em que tudo depende de um comando só: sem a fato carregada, nenhuma das cinco perguntas sai, e o README fica sem números. Para isso não custar a sua entrega inteira, existe uma saída combinada: se até 10/09 você não tiver o 04 rodando com 4.044 linhas, peça ajuda ao professor.

Tarefa 5 : Responder e recomendar

Escreva as cinco consultas e confira se os totais fecham com a origem. Depois, no README, responda cada pergunta em texto, com o número ao lado, e feche com uma recomendação de onde abrir a próxima loja dizendo também o que os dados não sustentam.

4.1. GRAVAÇÃO DE VÍDEO

Além do desenvolvimento das tarefas você deverá gravar um vídeo, com tempo máximo de 5 minutos, abordando os seguintes questionamentos:

- Qual o objetivo do modelo dimensional que você construiu? Mostre o diagrama e demonstre o funcionamento: rode uma das cinco consultas e mostre o resultado na tela.
- O que deve ser feito para reproduzir o seu banco do zero? Mostre em que ordem os scripts precisam ser executados.
- Como você organizou as tarefas antes de começar a construir o modelo?
- Quais decisões de tratamento você tomou máscara de data, de-para das grafias, padronização do nome da loja e por que tomou cada uma?
- O que os dados NÃO permitem afirmar? E o que você melhoraria no seu SQL se tivesse mais tempo?

Você poderá gravar na vertical ou na horizontal. É importante que apareça seu rosto e esteja em um local com boa iluminação. Para realizar a entrega do vídeo, coloque em uma pasta do Google Drive em modo leitor para qualquer pessoa com o link, e compartilhe o mesmo na submissão do projeto no AVA. Uma dica interessante é você inserir o vídeo no readme.md do seu projeto no repositório do GitHub.

5. CRITÉRIOS DE AVALIAÇÃO

A tabela abaixo apresenta os critérios que serão avaliados durante a correção do projeto. A tabela abaixo possui variação de nota de 0 (zero) a 10 (dez) como nota mínima e máxima, e possui peso de 25% sobre a avaliação do módulo.

Apresentação do Projeto			
Nº	Critério de Avaliação	0	2,00
1	Gravação de vídeo	Não foi realizada a gravação do vídeo.	O vídeo responde aos cinco questionamentos listados no item 4.1 e mostrou o diagrama do modelo, demonstrando ao menos uma das cinco consultas rodando.

Uso do GitHub e Readme.md				
Nº	Critério de Avaliação	0	0,5	1,00
2	Versionamento com branches e commits	O repositório do projeto não apresenta branches e commits.	O repositório do projeto apresenta parte das branches e commits distintos e nomeadas padronizadamente para cada funcionalidade desenvolvida.	O repositório do projeto apresenta branches e commits distintos e nomeados padronizadamente para cada etapa desenvolvida (setup, autenticação, autorização).

3	Diagnóstico da Origem no README	Não apresentou o diagnóstico no README ou omitiu a contagem da maioria dos itens solicitados. Os números apresentados estão incorretos ou inconsistentes com os dados de origem.	Registrou o diagnóstico no README, mas omitiu a contagem de um dos itens (ex.: não contou marcos de processo em branco) ou apresentou divergências pontuais nas métricas apuradas.	Registrou com precisão no README a contagem exata de todos os quatro itens da origem: grafias de loja, grafias de categoria, pedidos sem código de loja e marcos de processo em branco.
4	Respostas e Análise Crítica no README	Não respondeu às cinco perguntas no README, os números divergiram da origem tratada, ou não incluiu a leitura crítica e a recomendação final.	Respondeu às cinco perguntas com números bateram com a origem, porém a leitura crítica foi superficial (ou omitiu limitações do que os dados <i>não</i> permitem afirmar) ou a recomendação final foi genérica/ausente.	Apresentou as cinco respostas no README com reconciliação numérica perfeita em relação à origem, acompanhadas de uma leitura crítica bem fundamentada sobre as limitações dos dados e uma recomendação final clara e acionável.

Desenvolvimento do Projeto

Nº	Critério de Avaliação	0	1,50	3,00
5	Modelo dimensional	O grão da tabela fato não possui 4.044 linhas, há chaves estrangeiras (FKs) nulas na fato, faltam os registros de linha -1 nas dimensões ou a tabela ponte não aplica/implementa o fator de rateio.	Respeitou o grão de 4.044 linhas e tratou as FKs nulas, mas esqueceu a linha -1 em alguma dimensão ou a tabela ponte possui erros no cálculo/aplicação do fator de rateio.	O Modelo possui tabela fato estritamente com 4.044 linhas, todas as dimensões possuem o registro de linha -1, nenhuma FK está nula e a tabela ponte aplica o fator de rateio perfeitamente.
6	Tratamento dos dados	Falhou na conversão/máscara de datas, não aplicou a regra dos números, inverteu a ordem lógica do de-para de categoria ou realizou o <i>lookup</i> antes da padronização do nome da loja.	Aplicou a maioria das regras, mas cometeu uma falha pontual (ex.: padronizou o nome da loja somente após o <i>lookup</i> , ou errou a precedência da ordem lógica na regra do de-para).	Executou todo o pipeline de ETL corretamente: máscara de data no formato adequado, regra dos números aplicada, de-para de categoria na ordem lógica correta e padronização do nome da loja realizada obrigatoriamente antes do <i>lookup</i> .

Atenção: erros que custam nota:

- FK nula na fato em vez da linha -1.

- Total de pedidos diferente de 4.044 na fato: mais que isso é JOIN duplicando, menos é JOIN descartando linha.
- Percentual ou taxa gravados calculados dentro da fato eles não são aditivos.
- Soma por praça sem o fator de rateio: o faturamento estoura o total da rede.
- Etapa não cumprida gravada como 0 em vez de NULL.

Serão desconsiderados e atribuída a nota 0 (zero) os projetos que apresentarem plágio de soluções encontradas na internet ou de outros colegas. Lembre-se: você está livre para utilizar outras soluções como base, mas não é permitida a cópia.

6. ENCARTE - AS BASES QUE VOCÊ RECEBEU

Três tabelas, todas com todas as colunas em texto. Confira as contagens depois de rodar o 01-carga-staging.sql:

Tabela	O que é	Linhas
stg_pedido	Os pedidos + os 4 marcos do processo de entrega	4.044
stg_loja	Cadastro das 32 lojas a foto de hoje	32
stg_loja_praça	Loja × praça de atendimento, com o % do público	48

Os defeitos plantados, e o que cada um cobra:

Defeito	Onde	Conceito cobrado
Todas as colunas são texto	todas as stg_	staging × área de apresentação
Nomes fora de snake_case	Cod Loja, QTD.Itens	identificador entre delimitador
Dois formatos de data na MESMA tabela	stg_pedido	a máscara certa por coluna
18 grafias para 7 categorias	CategoriaProduto	dimensão guarda a grafia crua
“Ração Medicamentosa” não é ração	CategoriaProduto	a ordem do CASE importa
Dezenas de grafias de loja	Loja-Nome	padronizar antes do lookup
Cod Loja vazio em 39% das linhas	stg_pedido	resolver por nome
3 pedidos sem loja identificada	stg_pedido	linha -1; nunca FK nula
Sim/não escrito de muitas maneiras	HouveDesconto	padronizar na carga da fato
Canal escrito de muitas maneiras	CanalPedido	padronizar; WHATS antes de APP
Números em formatos misturados	todas as numéricas	a regra dos números

Defeito	Onde	Conceito cobrado
Loja em mais de uma praça	stg_loja_praca	bridge table com fator
Cadastro só com a foto de hoje	stg_loja	o passado foi sobrescrito (limite da P5)
2 datas por pedido na fato	stg_pedido	role-playing dimension
Marco em branco = processo aberto	stg_pedido	FK → -1, e NULL nos dias
Número do pedido sem atributos	NumeroPedido	dimensão degenerada

7. ENCARTE - O MODELO QUE VOCÊ DEVE CONSTRUIR

Uma fato, quatro dimensões e uma ponte. Duas dimensões já vêm prontas elas estão aqui para você saber o que tem dentro, não para construir.

FATO_PEDIDO -> grão -> 1 pedido : 4.044 linhas

Coluna	Tipo	O que é
sk_pedido	INT	PK da fato, gerada automaticamente.
numero_pedido	VARCHAR(20)	Número do pedido. Dimensão degenerada: código sem atributo, que por isso fica na fato.
sk_tempo_pedido	INT	FK para dim_tempo quando o cliente fez o pedido.
sk_tempo_entrega	INT	FK para dim_tempo quando chegou ao cliente. Vale -1 se a entrega ainda não aconteceu (1.953 pedidos).
sk_loja	INT	FK para dim_loja. Vale -1 nos 3 pedidos sem loja identificada.
sk_categoria	INT	FK para dim_categoria, encontrada pela grafia crua.
houve_desconto	VARCHAR(15)	Sim / Nao / Nao Informado. Padronizado na carga da fato.
canal_pedido	VARCHAR(20)	App / Site / Loja Fisica / Telefone / WhatsApp / Nao Informado.
dt_pedido	DATETIME/ TIMESTAMP	Data e hora do pedido.
qt_itens	INT	Itens do pedido. Aditiva.

Coluna	Tipo	O que é
vl_liquido	DECIMAL(15,2)	Valor faturado, em reais. Aditiva. É a métrica de faturamento.
dias_integracao_separacao	INT	Dias entre o ERP e a separação. Calculado na carga.
dias_separacao_nota	INT	Dias entre a separação e a nota fiscal.
dias_nota_despacho	INT	Dias entre a nota e o despacho.
dias_despacho_entrega	INT	Dias entre o despacho e a entrega.
dias_total_ate_entrega	INT	Dias do ERP até a entrega. Resposta direta da P1.

Repare no que NÃO está nessa lista. A stg_pedido também traz o valor bruto, o desconto em reais, unidades devolvidas, itens cancelados, peso e frete e nenhuma das cinco perguntas usa. Há UMA coluna de dinheiro na fato, e não três. Escolher o que não entra também é modelagem.

Como padronizar o desconto e o canal

Essas duas colunas não viram dimensão: são dois domínios de poucos valores, sem nada pendurado neles, e por isso ficam na própria fato. A padronização é feita UMA vez, no INSERT do arquivo 04. Use as duas tabelas abaixo.

O desconto chega escrito de 17 maneiras, e todas caem em três valores. Compare em UPPER e sem espaço nas pontas (TRIM):

Se o valor for	Grave
S, SIM, 1, X, TRUE, V	Sim
N, NAO, 0, FALSE, F	Nao
vazio, ou qualquer outra coisa	Nao Informado

No canal, A ORDEM DO CASE IMPORTA: "WHATSAPP" contém "APP". Se você testar APP antes de WHATS, os pedidos de WhatsApp vão para dentro do App e a P3 sai errada. Confira no 00-conferencia.sql: o WhatsApp tem de aparecer na fato, com 414 pedidos.

Ordem	Se contém	Grave
1	WHATS	WhatsApp
2	APP	App
3	SITE	Site
4	LOJA	Loja Fisica
5	TEL	Telefone

Ordem	Se contém	Grave
	nenhum dos acima	Nao Informado

DIM_TEMPO: JÁ VEM PRONTA -> 236 linhas

A chave é a própria data em número: 16/11/2023 vira 20231116. Por isso a fato monta a FK com uma conversão, sem JOIN. São 235 dias mais a linha -1. A fato usa a mesma dimensão em dois papéis (pedido e entrega): isso se chama role-playing dimension.

DIM_LOJA: JÁ VEM PRONTA -> 33 linhas

Coluna	Tipo	O que é
sk_loja	INT	PK.
cod_loja	VARCHAR(10)	Código da loja. É a chave natural e é por ela que a ponte liga.
chave_loja	VARCHAR(80)	O nome padronizado, em caixa alta e sem acento. É por ele que a fato encontra a loja.
nome_loja	VARCHAR(80)	O nome de exibição, para o relatório.
cidade / uf / mesorregiao	VARCHAR	Localização. A mesorregião permite agrupar acima da cidade.
populacao_cidade	INT	População da cidade. É o denominador da P5.
area_venda_m2	INT	Área de venda, em m².
porte	VARCHAR(20)	Pequena, Média ou Grande, pela área. Agrupa a P1 e a P2.
faixa_franquia	VARCHAR(15)	Bronze, Prata, Ouro ou Diamante. É a foto de HOJE e é isso que limita a P5.
formato_loja	VARCHAR(20)	Padrão, Completa ou Megastore.

DIM_CATEGORIA -> grão: uma grafia da origem 19 linhas (18 grafias + a -1)

A collation padrão do MySQL ignora acento e caixa, então o DISTINCT junta 'Racao', 'RACAO' e 'Ração' numa grafia só: sobram 18 grafias distintas mais a linha -1 = 19 linhas. O outro teste, e é o que mais importa, é o das 7 categorias padronizadas mais a linha -1 = 8.

Coluna	Tipo	O que é
sk_categoria	INT	PK.
categoria_origem	VARCHAR(50)	A grafia CRUA, como veio da origem. É por ela que a fato encontra a linha.

Coluna	Tipo	O que é
nome_categoria	VARCHAR(30)	O nome padronizado. É por ele que se agrupa na P2.
grupo_categoria	VARCHAR(20)	Alimentacao, Saude e Higiene, Bem-estar.

DIM_PRACA + BRIDGE_LOJA_PRACA 13 e 48 linhas

Uma loja entrega em mais de uma praça. Se você puser uma sk_praça dentro da dim_loja, terá de escolher UMA e vai perder as outras; dentro da fato, o mesmo problema. A ligação N:N não cabe em FK nenhuma: precisa de uma tabela própria, com o fator de rateio dentro.

Coluna	Tipo	O que é
sk_praça	INT	PK da dim_praça.
cod_praça	VARCHAR(10)	Código da praça. Chave natural.
nome_praça	VARCHAR(60)	Nome da praça de atendimento.
regional	VARCHAR(30)	Regional a que a praça pertence.
domicilios_com_pet	INT	Vem como '148.000': o ponto é milhar, não decimal.

Coluna (bridge)	Tipo	O que é
cod_loja	VARCHAR(10)	O CÓDIGO da loja, não a sk_loja. A chave natural atravessa recargas.
sk_praça	INT	FK para dim_praça.
fator_publico	DECIMAL(6,4)	0,85 = 85% do público daquela loja. Os fatores de uma loja somam 1,00, sempre.

Na P4 você multiplica o faturamento da loja pelo fator antes de somar por praça. Sem isso, o faturamento de quem atende duas praças seria contado duas vezes e a soma estouraria o total da rede.

8. ENCARTE - NÚMEROS DE CONFERÊNCIA

Estes números foram conferidos rodando o projeto inteiro. Use-os para saber se você está no caminho certo o arquivo 00-conferencia.sql traz cada um deles com a consulta pronta.

Etapas	O que conferir	Esperado
Depois do 01	stg_pedido / stg_loja / stg_loja_praça	4.044 / 32 / 48
Depois do 01	pedidos sem Cod Loja preenchido	1.575 (~39%)
Depois do 01	pedidos sem nome de loja	3

Etapa	O que conferir	Esperado
Depois do 01	marcos em branco (separação/nota/despacho/entrega)	1.077 / 1.338 / 1.665 / 1.953
Depois do 02	dim_tempo / dim_loja	236 / 33
Depois do 03	dim_categoria	19 linhas (18 grafias + a -1)
Depois do 03	categorias padronizadas (nome_categoria distintos)	8 = 7 + a linha -1
Depois do 03	dim_praca / bridge_loja_praca	13 / 48
Depois do 03	soma do fator por loja na ponte	1,00 em todas
Depois do 04	fato_pedido	4.044
Depois do 04	FKs nulas ou órfãs	0
Depois do 04	pedidos na linha -1 de loja	3
Depois do 04	pedidos com entrega não concluída (tempo -1)	1.953
Depois do 04	período dos pedidos	01/09/2023 a 31/03/2024
Depois do 05	faturamento total da rede	1.793.309
Depois do 05	soma rateada por praça + pedidos sem loja - total	0

Sobre os percentuais: no MySQL a divisão já devolve decimal automaticamente, então $100 * \text{SUM}(...) / \text{SUM}(...)$ funciona direto, sem CAST.

9. ANEXOS- Base de Dados para Utilização no Mini-Projeto

Seguem os links para utilização, a saber:

Pasta 01:

https://drive.google.com/drive/folders/1Wdninh1La_iLaBlun774dG4qZ7IPlggO?usp=drive_link

Pasta 02:

https://drive.google.com/drive/folders/1mpizpLISLRFM0FHleoe9XmNb4Cox9-KD?usp=drive_link

Pasta 03:

https://drive.google.com/drive/folders/1QxBOGso9pvtmNG2Rsc6ANZ5-c-UAI6-w?usp=drive_link